

AB тесты: статистика и базовые примеры.

Камалов Ирек.

22 июля 2022 г.

План презентации.

- ▶ Введение.
- ▶ Нормальные выборки.
- ▶ Биномиальные распределения.
- ▶ Пуассоновские распределения.
- ▶ Мультиномиальные распределения.
- ▶ Тест Манна-Уитни.
- ▶ Байесовское АВ тестирование (для бин. распр.)
- ▶ Заключение.

Введение.

- ▶ АВ тесты - стат. тесты для сравнения параметров 2 распредел.
- ▶ $H_0 : \theta_1 = \theta_2$
 $H_1 : \theta_1 \neq \theta_2 (< >)$
- ▶ Одностор. альтернатива - $\theta_1 > \theta_2 (<)$
- ▶ Двухстор. альтернатива - $\theta_1 \neq \theta_2$
- ▶ Данные обычно удовл. стат. соглашениям - выборки из нез. о.р. сл. в.

Введение.

- ▶ Используется для оценки значимости эксп. данных
- ▶ Пример - сравниваем конверсию страниц. Мы всегда знаем, какая страница оказалась лучше, но насколько результату можно доверять
- ▶ A/B/n тестирование - аналог для n групп

Нормальные выборки.

- ▶ Базовый случай: $\xi \sim N(\mu, \sigma^2)$, сравниваем мат. ожидания
- ▶ $X_1, X_2, \dots, X_n(\text{нез.}) \sim N(\mu_1, \sigma_1^2)$
 $Y_1, Y_2, \dots, Y_m(\text{нез.}) \sim N(\mu_2, \sigma_2^2)$
- ▶ $H_0 : \mu_1 = \mu_2$
 $H_1 : \mu_1 \neq \mu_2 (< >)$
- ▶ Примеры:
 1. Сравниваем цены квартир в Москве и в Петербурге
 2. Правда ли, что японские авто служат дольше корейских
 3. Сравниваем зар. плату по разным отраслям

Нормальные выборки.

T-тесты.

- ▶ Используем t-критерии (Стьюдента, Уэлча)
- ▶ На этом примере рассм. 2 вида альт. гипотез: одностор. и двухстор.





Рис.: Одностор. и двухстор. критические области уровня α .

Бином. распределения.

- ▶ ξ - количество успехов в n независимых исп. Бернулли, вер. усп. p
- ▶ $X \sim \text{Bin}(n_1, p_1), Y \sim \text{Bin}(n_2, p_2)$
- ▶ $H_0 : p_1 = p_2$
 $H_1 : p_1 \neq p_2 (< >)$
- ▶ Примеры:
 1. Конверсия 2 страниц (кол-во кликов посетителей по кнопке)
 2. Эффективность лекарства (делим людей на 2 гр., одна получает вакцину, другая плацебо)
 3. Социология - процент опр. людей в группах

Бином. распределения.

Z-test.

- ▶ $\xi \sim \text{Bin}(n, p) \Rightarrow \xi \xrightarrow{d} N(np, np(1 - p))$ (ЦПТ)
- ▶ То есть

$$X \xrightarrow{d} N(n_1 p_1, n_1 p_1 q_1), Y \xrightarrow{d} N(n_2 p_2, n_2 p_2 q_2)$$

- ▶ При верной H_0 $\text{distr}(X/n_1 - Y/n_2) \approx N(0, \sigma^2)$
- ▶ Считаем, что n_1, n_2 велики, для дов. интервала остаётся оценить дисперсию

Бином. распределения.

► 2 варианта оценки

1. pooled prop. $\hat{\sigma} = \sqrt{\hat{p}(1 - \hat{p})(1/n_1 + 1/n_2)}$
 $\hat{p} = \frac{n_1 p_1 + n_2 p_2}{n_1 + n_2}$

2. unpooled prop. $\hat{\sigma} = \sqrt{\hat{p}_1(1 - \hat{p}_1)/n_1 + \hat{p}_2(1 - \hat{p}_2)/n_2}$

► Получаем $[-z_{\alpha/2}\hat{\sigma}, +z_{\alpha/2}\hat{\sigma}]$, либо полуинтервал для одностор. альт.

► Считаем реальное $X/n_1 - Y/n_2$ и сравниваем с границами

Бином. распределения.

Точный тест Фишера.

- ▶ Используется при небольших выборках
- ▶ Составляем факторную таблицу. Для простоты рассм. на примере
- ▶ Есть 2 группы - мужчины и женщины, изучаем их склонность к диете
- ▶ Данные отражены в табл.

	Мужчины	Женщины	Всего
На диете	1	9	10
Не на диете	11	3	14
Всего	12	12	24

Бином. распределения.

Точный тест Фишера.

	Мужчины	Женщины	Всего
На диете	a=1	b=9	D=10
Не на диете	c=11	d=3	14
Всего	n=12	12	N=24

- ▶ При верной H_0 мы можем посчитать вероятность наблюдать такую таблицу
- ▶ С помощью комб. получаем

$$p = \binom{a+b}{a} \binom{c+d}{c} / \binom{N}{a+c} = \frac{(a+b)! (c+d)! (a+c)! (b+d)!}{N! a! b! c! d!}$$

гипергеометрическое распределение на а с парам. N, D, n

Бином. распределения.

Точный тест Фишера.

	Мужчины	Женщины	Всего
На диете	$a=1$	$b=9$	$D=10$
Не на диете	$c=11$	$d=3$	14
Всего	$n=12$	12	$N=24$

- ▶ Работаем с фиксир. N , D , n
- ▶ Стат. значимость набл-ых данных - их вероятность + вероятность более редких таблиц.
- ▶ $p - val = P(a = 1|N, D, n) + P(a = 0|N, D, n) = 0.00138$
- одностор. альт. "женщины более склонны"
- ▶ $p - val = P(a = 1|N, D, n) + P(a = 0|N, D, n) + P(a = 9|N, D, n) + P(a = 10|N, D, n) = 0.0028$
- двухстор. альт. "склонности просто различны"

Пуассоновские распределения.

- ▶ Количество успехов в нез. испытаниях Бернулли с очень большим числом n
- ▶ $P(\xi = k) = \frac{\lambda^k}{k!} e^{-\lambda}$
- ▶ $X \sim \text{Pois}(\lambda_1), Y \sim \text{Pois}(\lambda_2)$
- ▶ $H_0 : \lambda_1 = \lambda_2$
 $H_1 : \lambda_1 \neq \lambda_2 (< >)$
- ▶ Примеры
 1. Правда ли, что Яндекс.Еда получает больше заказов в неделю чем Delivery Club
 2. Сравниваем кол-во пациентов в день в двух клиниках
 3. Сравниваем частоту транзакций у 2 типов пользователей
 4. Правда ли, что в апреле столько же дождей, что в сентябре

Пуассоновские распределения.

C-тест (conditional)

- ▶ Сводим пуасс. распр. к биномиальному:
 $(X|X + Y = k) \sim \text{Bin}(k, p), p = \left(\frac{n_1}{n_2}\right)\left(\frac{\lambda_1}{\lambda_2}\right)\left(1 + \left(\frac{n_1}{n_2}\right)\left(\frac{\lambda_1}{\lambda_2}\right)\right)$
- ▶ Далее считаем ур. значимости
- ▶ $P(X \geq k_1|k, p) = \sum_{i=k_1}^k \binom{n}{i} p^i (1-p)^{k-i}$ - одностор.
альтернатива, k_1 - наблюдаемое значение X
- ▶ $2 * \min\{P(X \geq k_1|k, p), P(X \leq k_1|k, p)\}$ - двухстор. альт.

Мультином. распределения.

- ▶ Рассм. нез. испытания с k возм. исходами (соотв. k событиям). Их вер-сти p_1, p_2, \dots, p_k
- ▶ ξ_i - количество наступлений события A_i среди n исп.
- ▶ $P(\xi_1 = m_1, \dots, \xi_k = m_k)$ - мультином. распр.
- ▶ Имеем 2 мультином. распр. $M(p_1, \dots, p_k), M(q_1, \dots, q_k)$
- ▶ $H_0 : p_1, \dots, p_k = q_1, \dots, q_k$
 $H_1 : p_1, \dots, p_k \neq q_1, \dots, q_2$ (только двухстор. альт.)

Мультином. распределения.

Примеры.

1. Курс студентов делят на 2 потока перед экзаменом. Имеем частоты оценок 2, 3, 4, 5 для двух потоков, хотим проверить их однородность
2. Правда ли, что мужчины и женщины совершают одинаковые объёмы покупок по выбранным категориям
3. Одинаковое ли распределение по специальностям на рынке труда в Москве и в Петербурге

Мультином. распределения.

Критерий однородности χ^2 .

- ▶ $\mu_1, \dots, \mu_k; \nu_1, \dots, \nu_k$ - наблюдаемые частоты данных событий
- ▶ Статистика критерия:

$$\chi^2 = n_1 n_2 \sum_{i=1}^k \frac{(\mu_i/n_1 - \nu_i/n_2)^2}{\mu_i + \nu_i}, \quad n_1 = \sum_{i=1}^k \mu_i, \quad n_2 = \sum_{i=1}^k \nu_i$$

- ▶ $\mu_i/n_1 \xrightarrow{d} N(p_i, p_i q_i)$ (ЦПТ), ν_i/n_2 аналог.
- ▶ При верной H_0 $\chi^2 \sim \chi^2(k-1)$
- ▶ Для α находим кр. конст. через таблицу $\chi^2(k-1)$
- ▶ Если наблюдаем χ^2 больше константы, отвергаем H_0

Тест Манна-Уитни.

- ▶ Если о распределении ничего не известно, можем исп. ранги в упор. выборке
- ▶ X_1, X_2, \dots, X_{n_1} (нез.); Y_1, Y_2, \dots, Y_{n_2} (нез.)
- ▶ $H_0 : F_X(u) = F_Y(u) \quad \forall u \in \mathbb{R}$
 $H_1 : F_X(u) \neq F_Y(u) (< > \forall u \in \mathbb{R})$
- ▶ Основное применение - медицина, психология. Например, сравнить баллы по психол. тесту среди групп.

Тест Манна-Уитни.

- ▶ Объединяем $\{X_i\}, \{Y_j\}$ в упор. ряд
- ▶ R_1, R_2 - суммы рангов $\{X_i\}, \{Y_j\}$ в данном ряду
- ▶ $U_1 = n_1 \cdot n_2 + \frac{n_1 \cdot (n_1 + 1)}{2} - R_1,$
 $U_2 = n_1 \cdot n_2 + \frac{n_2 \cdot (n_2 + 1)}{2} - R_2,$
если всё вычислено верно, то $U_1 + U_2 = n_1 \cdot n_2.$
- ▶ $U = \min\{U_1, U_2\}$
- ▶ Для α, n_1, n_2 наход. *crit*, если $U \notin \text{crit}$, отвергаем H_0
- ▶ $U \xrightarrow{d} N(n_1 n_2 / 2, n_1 n_2 (n_1 + n_2 + 1) / 12),$
обычно приближ. хорошее уже при $n_1, n_2 \geq 20$

Байесовское АВ тестирование (для бин. распр.).

- ▶ Вновь рассм. 2 бином. сл. в.
 $X \sim \text{Bin}(n_1, p_1)$, $Y \sim \text{Bin}(n_2, p_2)$, сравниваем p_1, p_2
- ▶ Рассмотрим отдельно некот. $\xi \sim \text{Bin}(n, \theta_0)$
- ▶ Введём сл. в. θ с распр. $p(\theta)$, которая моделирует параметр θ_0
- ▶ Также имеем $p(\theta|\xi = k)$ - апост. распр. данной величины, $P(\xi = k|\theta)$ - ф. правдоподобия
- ▶ По ф. Байеса
$$p(\theta|\xi = k) = \frac{P(\xi=k|\theta)p(\theta)}{\int_{-\infty}^{+\infty} P(\xi=k|\theta)p(\theta)d\theta}$$
- ▶ Как оценить интеграл?

Байесовское АВ тестирование (для бин. распр.).

- ▶ По ф. Байеса $p(\theta|\xi = k) = \frac{P(\xi=k|\theta)p(\theta)}{\int_{-\infty}^{+\infty} P(\xi=k|\theta)p(\theta)d\theta}$
- ▶ Если взять в качестве $p(\theta)$ сопряж. распр. к $P(\xi = k|\theta)$, то интеграл можно найти аналитически
- ▶ Сопряж. распр. $p(\theta)$ инвариантно отн. умнож. на $P(\xi = k|\theta)$ (меняются лишь параметры)
- ▶ Для бином. распр. сопряж. является бета-распр.
 $Beta(a, b), p(x) = \frac{1}{B(a,b)} x^{a-1} (1-x)^{b-1}$
- ▶ Различные парам. a, b порождают разные априорн. распр., в которых мы будем оценивать параметр

Байесовское АВ тестирование (для бин. распр.).

- ▶ По ф. Байеса $p(\theta|\xi = k) = \frac{P(\xi=k|\theta)p(\theta)}{\int_{-\infty}^{+\infty} P(\xi=k|\theta)p(\theta)d\theta}$
- ▶ При $a = b = 1$, $Beta(a, b) = R[0, 1]$
- ▶ Получим $(\theta|\xi = k) \sim Beta(k + 1, n - k + 1)$
- ▶ Далее можем смоделировать искомые p_1, p_2






Рис.: Апостериорные распр-ия конверсии.

Байесовское АВ тестирование (для бин. распр.).

- ▶ Требуется использовать этот рез-тат, чтобы оценить значимость набл. данных
- ▶ Для этого строим совместную плотность апост. конверсий



- ▶ Вероятность правильного решения - интеграл плотности по полуплоскости $y \geq x$

Заключение.

- ▶ Были рассм. основные мат. модели АВ тестов
- ▶ К ним были даны базовые примеры из прикл. областей
- ▶ Отд. внимание было уделено байесовскому подходу
- ▶ Был составлен .ipynb с реализацией моделей
- ▶ Не была рассмотрена связь АВ тестов с uplift modeling, будет далее